

بهینه‌سازی محدب ۱ (۱-۲۵۷۵۶)



تمرین سری ششم

ترم بهار ۱۴۰۱-۰۲

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

استاد: دکتر محمدحسین یاسائی میبدی

مهلت تحویل: یک‌شنبه ۲۱ خرداد ۱۴۰۲، ساعت ۱۱:۵۹

(*) مسائلی که با ستاره مشخص شده‌اند امتیازی هستند و حل کردن آن‌ها نمره‌ی امتیازی خواهد داشت!

۱ کاهش گرادیان برای توابع مربعی!

در این مسئله به تحلیل الگوریتم کاهش گرادیان برای تابع ساده مربعی زیر می پردازیم:

$$f(x) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c$$

فرض کنید که در قدم t ام از اندازه η_t استفاده می‌کنیم، یعنی:

$$\mathbf{x}_{t+1} = \mathbf{x}_t - \eta_t \nabla f(\mathbf{x}_t).$$

۱. نشان دهید:

$$\mathbf{x}_{t+1} = (\mathbf{I} - \eta_t \mathbf{A}) \mathbf{x}_t + \eta_t \mathbf{b}.$$

۲. فرض کنید \mathbf{x}^* نقطه‌ی بهینه‌کننده تابع f باشد. علت درستی روابط زیر را بیان کنید:

$$\begin{aligned} \mathbf{x}_{t+1} - \mathbf{x}^* &= (\mathbf{x}_t - \eta_t(\mathbf{A}\mathbf{x}_t - \mathbf{b})) - (\mathbf{x}^* - \eta_t(\mathbf{A}\mathbf{x}^* - \mathbf{b})) \\ &= (\mathbf{I} - \eta_t \mathbf{A})(\mathbf{x}_t - \mathbf{x}^*) = \prod_{k=1}^t (\mathbf{I} - \eta_k \mathbf{A})(\mathbf{x}_1 - \mathbf{x}^*) \end{aligned}$$

۳. حال علت درستی روابط زیر را بیان کنید:

$$\begin{aligned} \|\mathbf{x}_{t+1} - \mathbf{x}^*\| &\leq \left\| \prod_{k=1}^t (\mathbf{I} - \eta_k \mathbf{A}) \right\|_2 \|\mathbf{x}_1 - \mathbf{x}^*\|_2 \\ &\leq \left(\prod_{k=1}^t \|\mathbf{I} - \eta_k \mathbf{A}\|_2 \right) \|\mathbf{x}_1 - \mathbf{x}^*\|_2. \end{aligned}$$

دقت کنید که نرم در نظر گرفته شده نرم عملگری ماتریس است که برابر با بزرگ‌ترین مقدار ویژه‌ی ماتریس است.

۴. حال فرض کنید که تابع f ، M -هموار و m -قویاً محدب باشد. نشان دهید که دو شرط فوق معادل است با:

$$\frac{m}{M} \mathbf{I} \preceq \frac{1}{M} \mathbf{A} \preceq \mathbf{I}.$$

و در نتیجه:

$$\|I - \frac{1}{\beta}A\|_2 = 1 - \frac{\alpha}{\beta} = 1 - \frac{1}{\kappa}$$

که در آن α کوچک‌ترین مقدار ویژه A و β بزرگ‌ترین مقدار ویژه آن می‌باشد.

۵. با استفاده از قسمت‌های قبل نشان دهید که برای قدم ثابت $\eta_t = \frac{1}{M}$ داریم:

$$\|x_{t+1} - x^*\|_2 \leq \exp\left(-\frac{t}{\kappa}\right) \|x_1 - x^*\|_2.$$

که در آن κ عدد حالت ماتریس A است.

۲ نیوتون!

فرض کنید $f: \mathbb{R}^n \rightarrow \mathbb{R}$ یک تابع محدب و دوبار مشتق‌پذیر با مشتقات پیوسته است. فرض کنید ∇f تابع L -لیدشیتز است و f یک تابع قویاً محدب با پارامتر $m > 0$ است و فرض کنید $\nabla^2 f$ یک تابع M -لیپشیتز است یعنی:

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_{\text{op}} \leq M \|x - y\|_2$$

فرض کنید x^* نقطه‌ی کمینه‌کننده‌ی سراسری f باشد.

۱. نشان دهید که برای هر x داریم:

$$f(x) - f(x^*) \leq \frac{1}{2m} \|\nabla f(x)\|_2^2.$$

۲. نشان دهید برای تکرار مرحله‌ی t -ام الگوریتم نیوتن داریم:

$$\frac{M}{2m^2} \|\nabla f(x_{t+1})\|_2 \leq \left(\frac{M}{2m^2} \|\nabla f(x_t)\|_2 \right)^2.$$

۳. فرض کنید که بعد از k_0 مرحله، شرط زیر را داریم:

$$\|\nabla f(x_{k_0})\|_2 < \eta \leq \frac{m^2}{M}$$

نشان دهید برای $k > k_0$:

$$f(x_k) - f(x^*) \leq \frac{2m^2}{M^2} \left(\frac{1}{2} \right)^{2^{k-k_0+1}}$$

۳ چند پرسش!

به پرسش‌های زیر پاسخ دهید:

۱. فرض کنید f یک تابع محدب است و روی یک مجموعه‌ی محدب و بسته تعریف شده است. ثابت کنید f یک تابع قویاً محدب با پارامتر m است اگر و تنها اگر ∇f^* یک تابع $\frac{1}{m}$ -لیپشیتز باشد. (f^* تابع مزدوج f است.)

۲. مساله‌ی بهینه‌سازی زیر را در نظر بگیرید:

$$\begin{aligned} & \text{Minimize}_{\mathbf{x}} \quad f(\mathbf{x}) \\ & \text{subject to:} \quad \mathbf{Ax} = \mathbf{b} \end{aligned}$$

الگوریتم زیر با انتخاب یک نقطه‌ی اولیه‌ی $\mathbf{u}^{(0)}$ برای حل این مساله داده شده است.

$$\begin{aligned} \mathbf{x}^{(k)} & \in \arg \min_{\mathbf{z}} f(\mathbf{z}) + \left(\mathbf{u}^{(k-1)} \right)^\top \mathbf{Az} \\ \mathbf{u}^{(k)} & = \mathbf{u}^{(k-1)} + t_k (\mathbf{Ax}^{(k)} - \mathbf{b}) \end{aligned}$$

که در آن t_k اندازه‌ی گام (نرخ یادگیری) برای به‌روزرسانی $\mathbf{u}^{(k)}$ است. آیا می‌توانید بگویید این الگوریتم از چه مساله‌ای نشأت گرفته است؟
 راهنمایی: مساله‌ی دوگان را در نظر گرفته و در صدد برقراری شرط صفر بودن گرادیان تابع هدف برآید.

۳. الگوریتم ارائه شده در قسمت قبل را یک بار دیگر برای تابع f با شرط قویاً محدب با پارامتر m و همچنین یک‌بار برای تابع f با شرط قویاً محدب با پارامتر m و گرادیان L لیپشیتز آنالیز همگرایی کنید و تعداد مراحل همگرایی با خطای ϵ را به دست آورید. راهنمایی: می‌توانید از آنالیز همگرایی کاهش گرادیان استفاده کنید.

۴ روش گرادیان و شروط تساوی!

در این سوال به دنبال یافتن تعمیم روش گرادیان برای مسائل دارای شروط تساوی خواهیم بود. فرض کنید که f یک تابع محدب و مشتق پذیر باشد، و $\mathbf{x} \in \text{dom } f$ در شرط $\mathbf{Ax} = \mathbf{b}$ صدق کند، که در آن $\mathbf{A} \in \mathbb{R}^{p \times n}$ با $\text{rank}(\mathbf{A}) = p < n$ است. تصویر اقلیدسی منفی گرادیان $-\nabla f(\mathbf{x})$ بر روی $\text{null}(\mathbf{A})$ توسط رابطه‌ی زیر داده می‌شود:

$$\Delta \mathbf{x}_{\text{pg}} = \arg \min_{\mathbf{Au}=\mathbf{0}} \|\nabla f(\mathbf{x}) - \mathbf{u}\|_2$$

۱. فرض کنید که (\mathbf{v}, \mathbf{w}) جواب یکتای مسئله‌ی زیر باشند.

$$\begin{bmatrix} \mathbf{I} & \mathbf{A}^\top \\ \mathbf{A} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{v} \\ \mathbf{w} \end{bmatrix} = \begin{bmatrix} -\nabla f(\mathbf{x}) \\ \mathbf{0} \end{bmatrix}$$

نشان دهید که :

$$\mathbf{v} = \Delta \mathbf{x}_{\text{pg}}$$

و

$$\mathbf{w} = \arg \min_{\mathbf{y}} \|\nabla f(\mathbf{x}) + \mathbf{A}^\top \mathbf{y}\|_2.$$

۲. رابطه‌ی بین منفی گرادیان تصویر شده یعنی $\Delta \mathbf{x}_{\text{pg}}$ و منفی گرادیان مسئله‌ی کاهش یافته که به فرمت زیر است:

$$\text{Minimize } \tilde{f}(\mathbf{z}) = f(\mathbf{Fz} + \hat{\mathbf{x}})$$

و با فرض آنکه داشته باشیم $\mathbf{Ax} = \mathbf{b}$ ، $\mathbf{Fz} \in \text{null}(\mathbf{A})$ و $\mathbf{F}^\top \mathbf{F} = \mathbf{I}$ چیست؟

۳. روش گرادیان تصویر شده برای حل یک مسئله‌ی بهینه‌سازی با شروط تساوی از طول گام $\Delta \mathbf{x}_{\text{pg}}$ و روش جستجوی خط backtracking بر روی f استفاده می‌کند. با استفاده از بخش قبل، شروطی را مطرح کنید که تحت آن روش گرادیان تصویر شده به جواب بهینه همگرا شود. فرض کنید که نقطه‌ی شروع الگوریتم نقطه‌ی $\mathbf{x}_0 \in \text{dom } f$ است که در شرط $\mathbf{Ax}_0 = \mathbf{b}$ صدق می‌کند.

۵ (*) طراحی آزمایش!

مسائل زیر در طراحی آزمایشی مطرح می‌شوند:
 الف) مسئله‌ی طراحی D-optimal:

$$\begin{aligned} \text{Minimize} \quad & \log \det \left\{ \left(\sum_{i=1}^p x_i \mathbf{v}_i \mathbf{v}_i^\top \right)^{-1} \right\} \\ \text{subject to:} \quad & \mathbf{x} \succeq \mathbf{0}, \quad \mathbf{1}^\top \mathbf{x} = 1 \end{aligned}$$

ب) مسئله‌ی طراحی A-optimal:

$$\begin{aligned} \text{Minimize} \quad & \text{tr} \left\{ \left(\sum_{i=1}^p x_i \mathbf{v}_i \mathbf{v}_i^\top \right)^{-1} \right\} \\ \text{subject to:} \quad & \mathbf{x} \succeq \mathbf{0}, \quad \mathbf{1}^\top \mathbf{x} = 1 \end{aligned}$$

دامنه‌ی هر دوی این مسائل $\{\mathbf{x} \mid \sum_{i=1}^p x_i \mathbf{v}_i \mathbf{v}_i^T \succ \mathbf{0}\}$ است، که در آن متغیر $\mathbf{x} \in \mathbb{R}^p$ است و بردارهای $\mathbf{v}_1, \dots, \mathbf{v}_p \in \mathbb{R}^n$ داده شده‌اند.

دوگان مسائل فوق را با تعریف یک متغیر جدید $\mathbf{X} \in \mathbf{S}^n$ و هم چنین اضافه کردن شرط تساوی $\mathbf{X} = \sum_{i=1}^p x_i \mathbf{v}_i \mathbf{v}_i^T$ سپس به کار بردن روش لاگرانژین بیابید. مسائل دوگان را تا جایی که می‌شود ساده کنید.